

Wyższa Szkoła Bankowa

# Uczenie Maszynowe

Ćwiczenia 1 - zadania

Autorzy: Marcin Doroszko 135670 , Dawid Szwarc 99434,  
Kuba Ślaboń 135514  
Wrzesień 2023

## Spis treści

Rozdział 1 – Polecenia.....	2
Rozdział 2 - Rozwiązańa .....	2
Rozdział 3 – Podsumowanie i wnioski .....	19

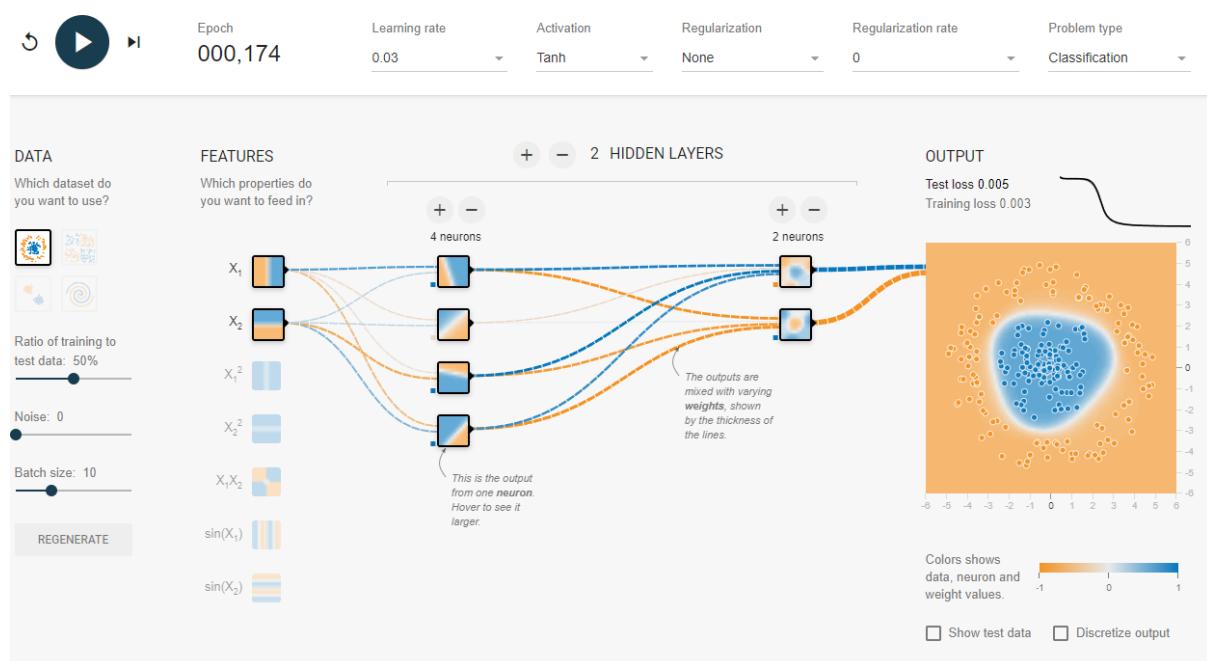
## Rozdział 1 – Polecenia

Na podstawie <https://playground.tensorflow.org> wykonać następujące zadania:

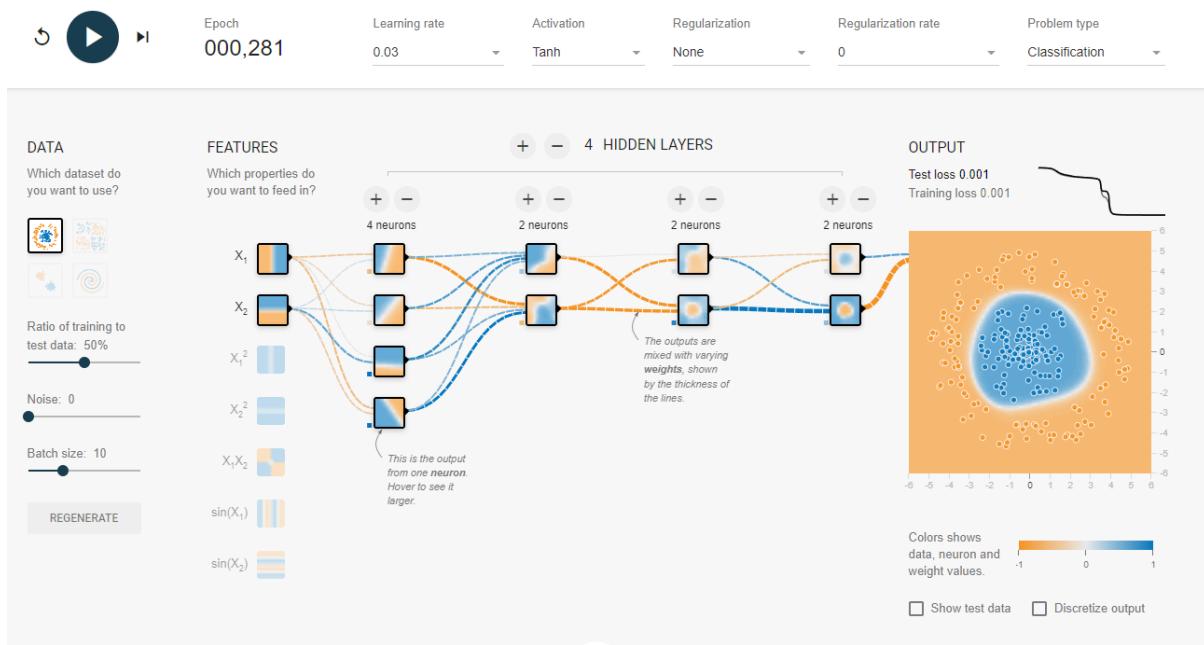
1. Przeprowadzić badania 7 różnych architektur sieci (różne ilości ukrytych warstw, zmiana ilości neuronów).
2. Sprawdzić wpływ learning rate, activation, regularization regularization rate dla problemu klasyfikacji i dwóch różnych typów zbiorów.
3. Sprawdzić wpływ rozmiaru batch size.
4. Sprawdzić wpływ szumu.
5. Sprawdzić wpływ wielkości testowego zbioru.
6. Wyjaśnić pojęcia learning rate, regularization oraz regularization rate.
7. Wyniki razem ze zrzutami ekranu dodać do sprawozdania

## Rozdział 2 - Rozwiązania

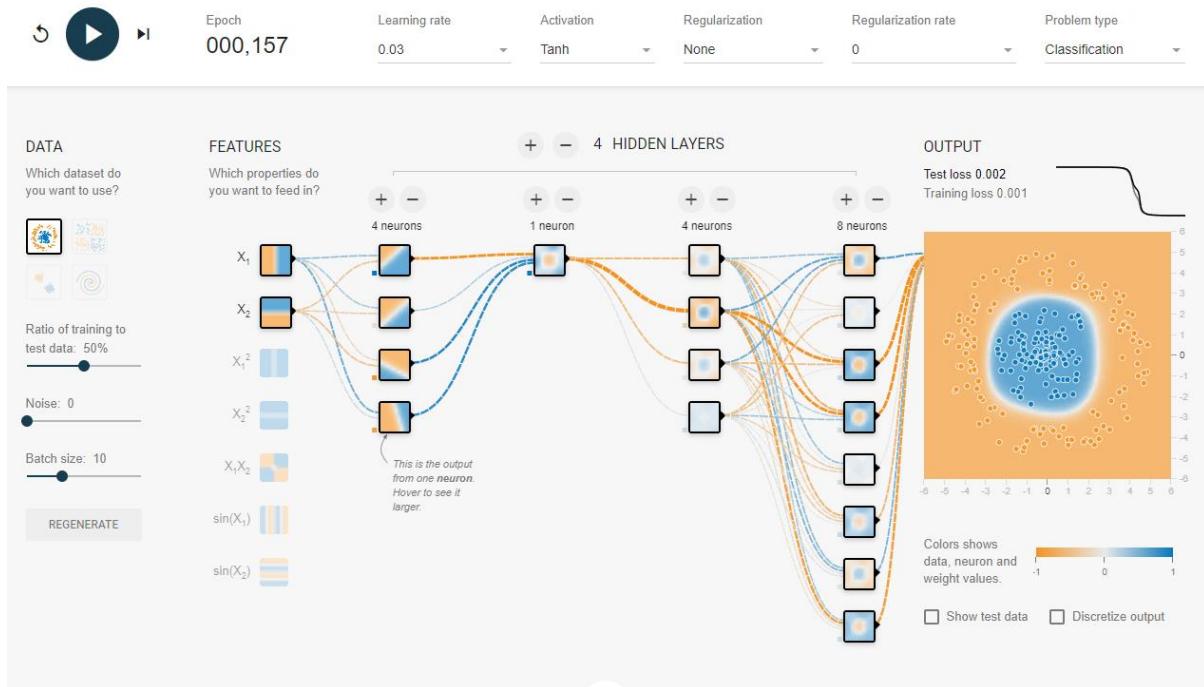
### 1.1



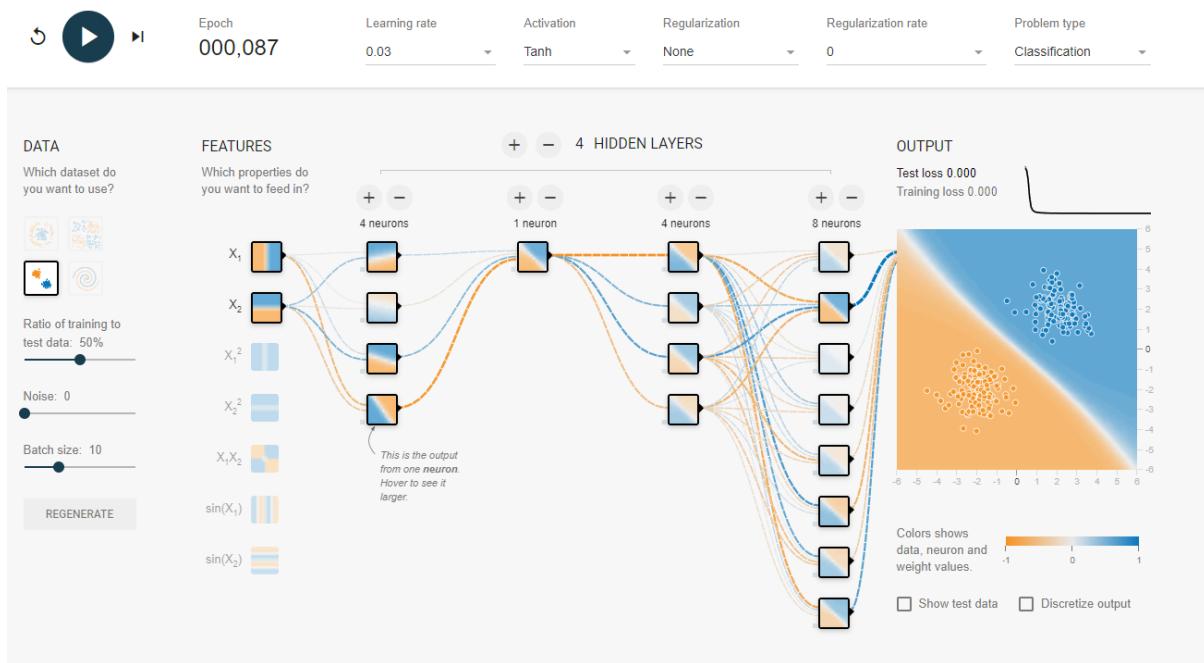
1.2



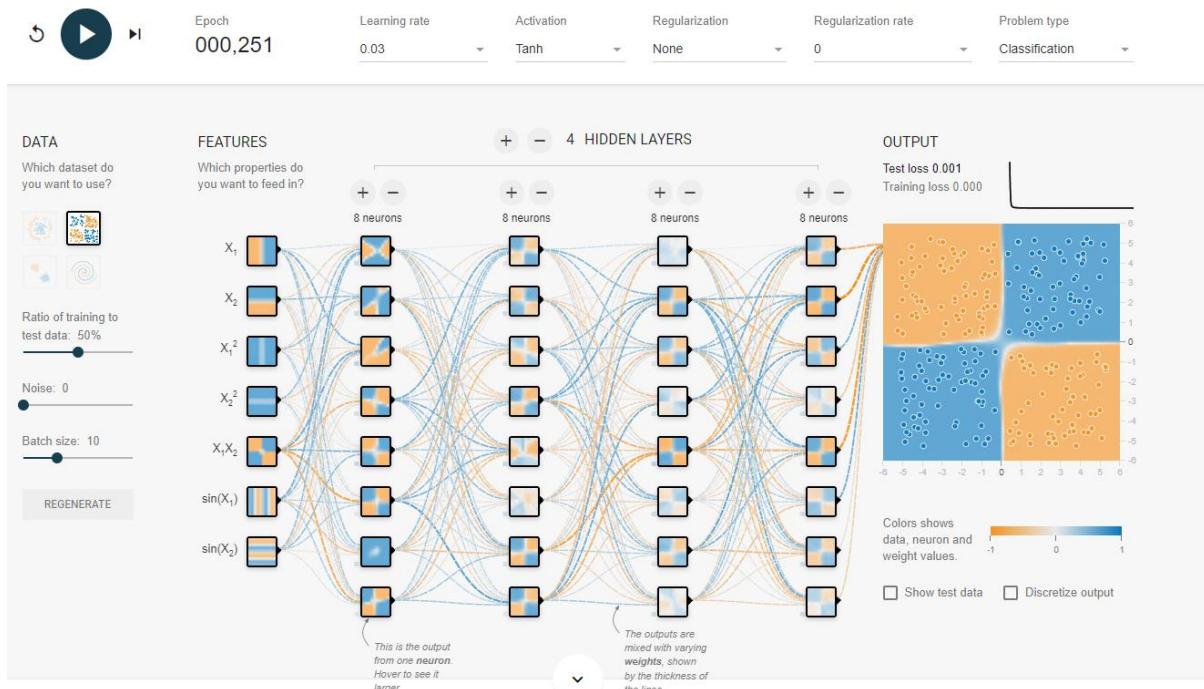
1.3



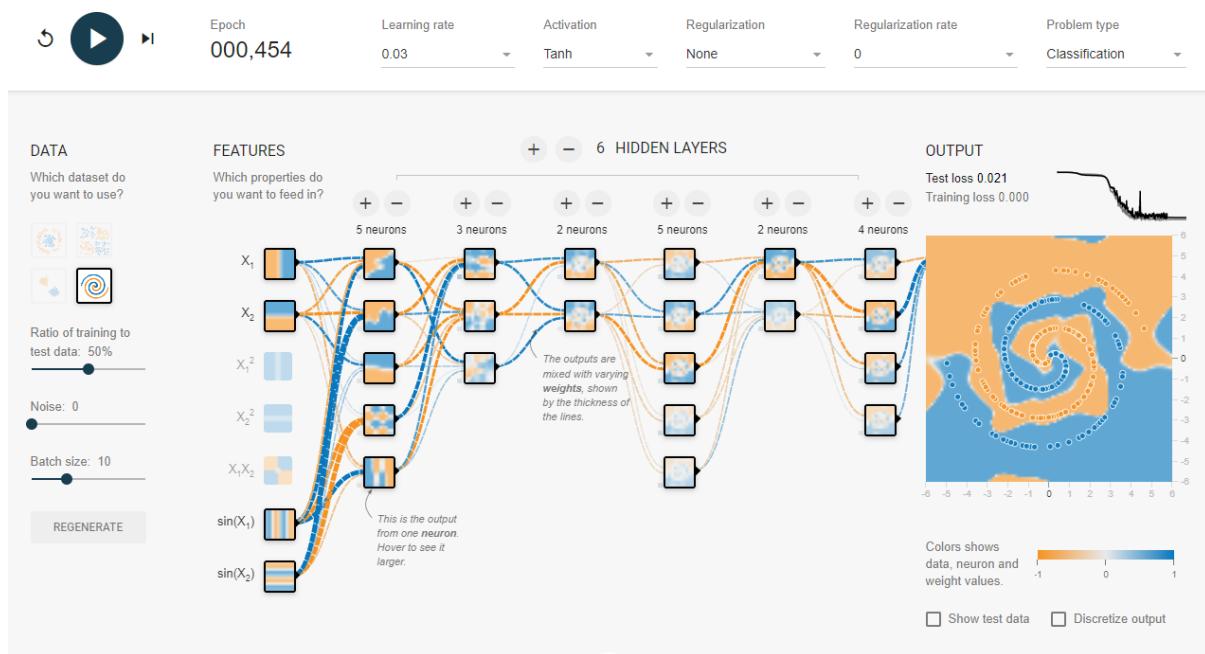
1.4



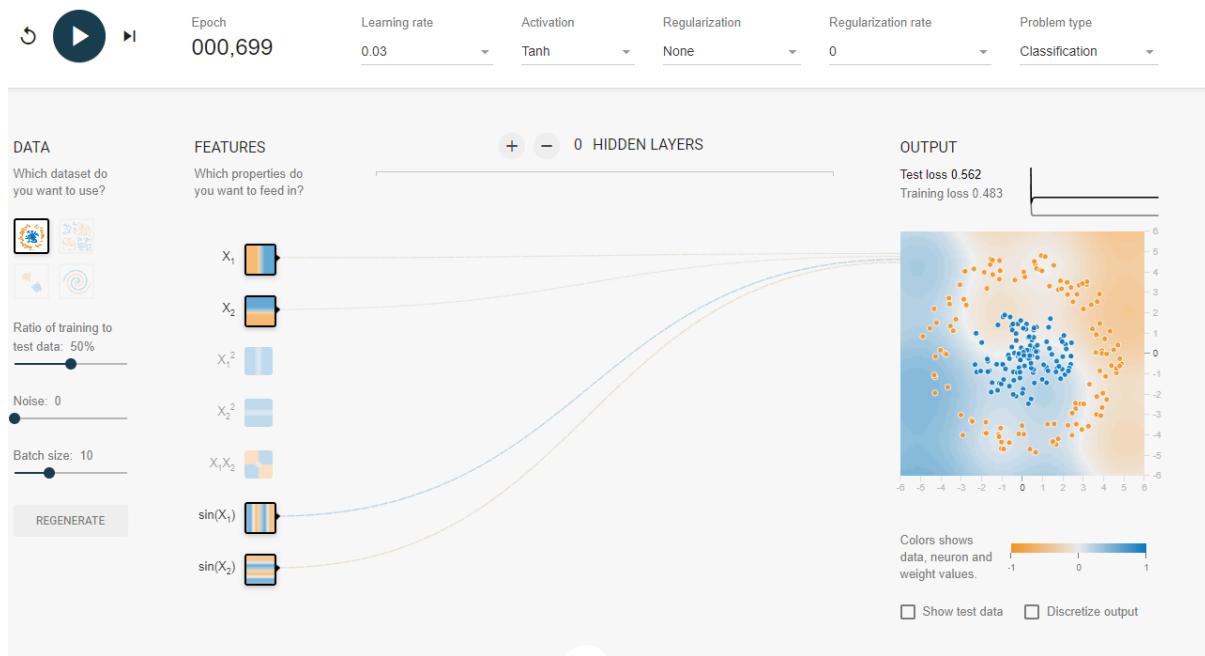
1.5



1.6

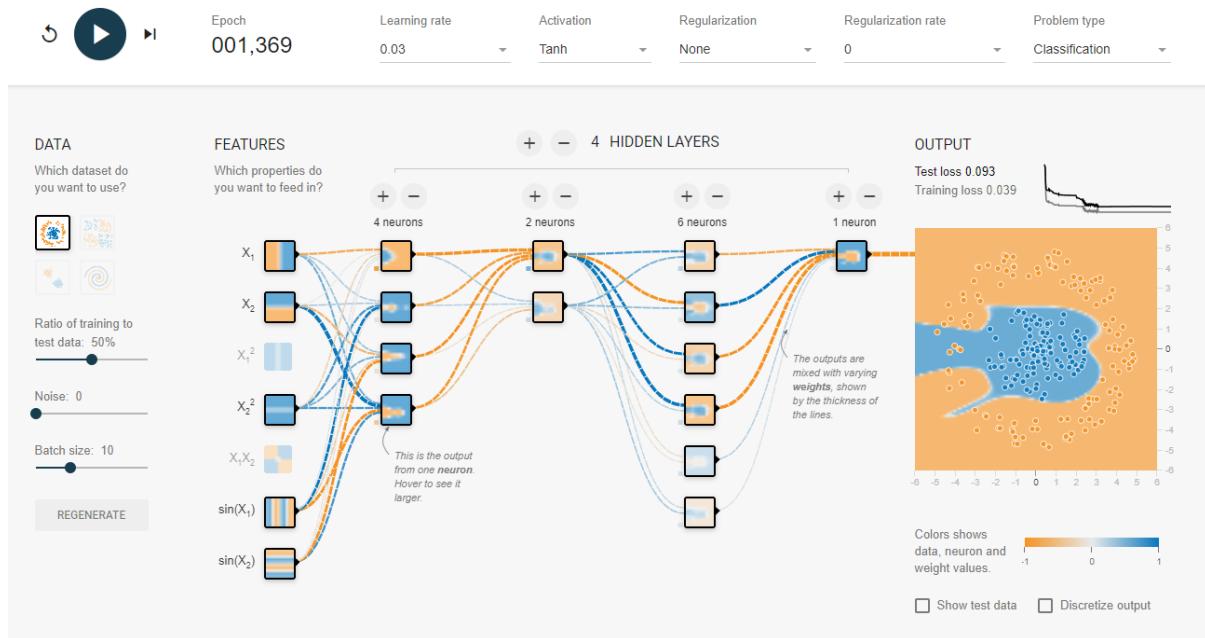


1.7

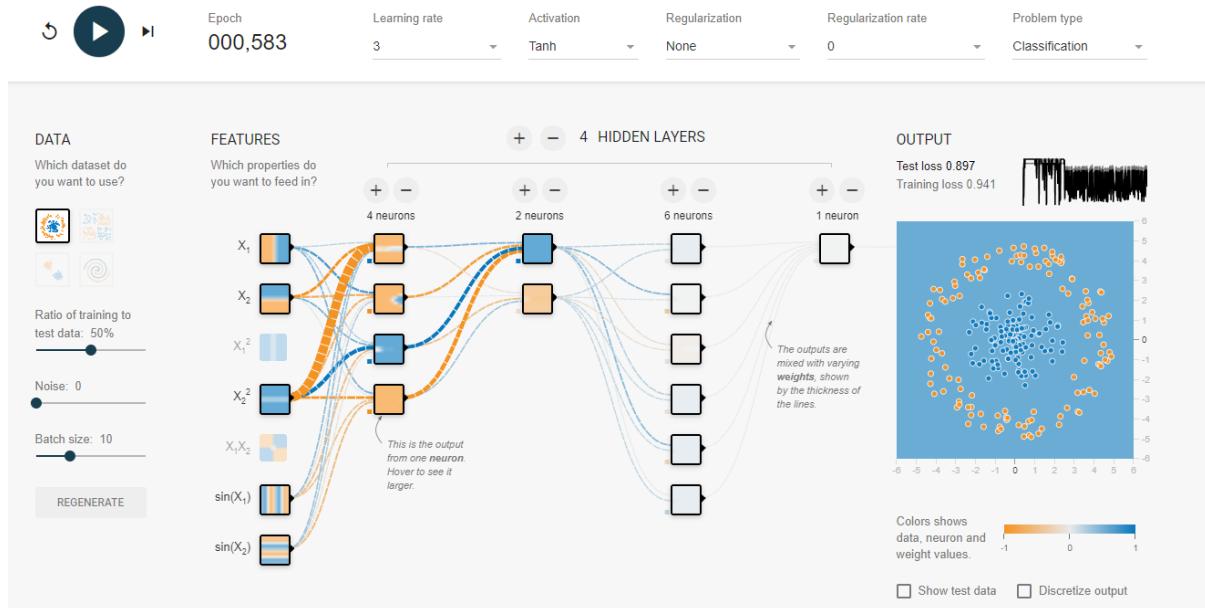


## 2.1 Learning Rate Typ Zbioru 1:

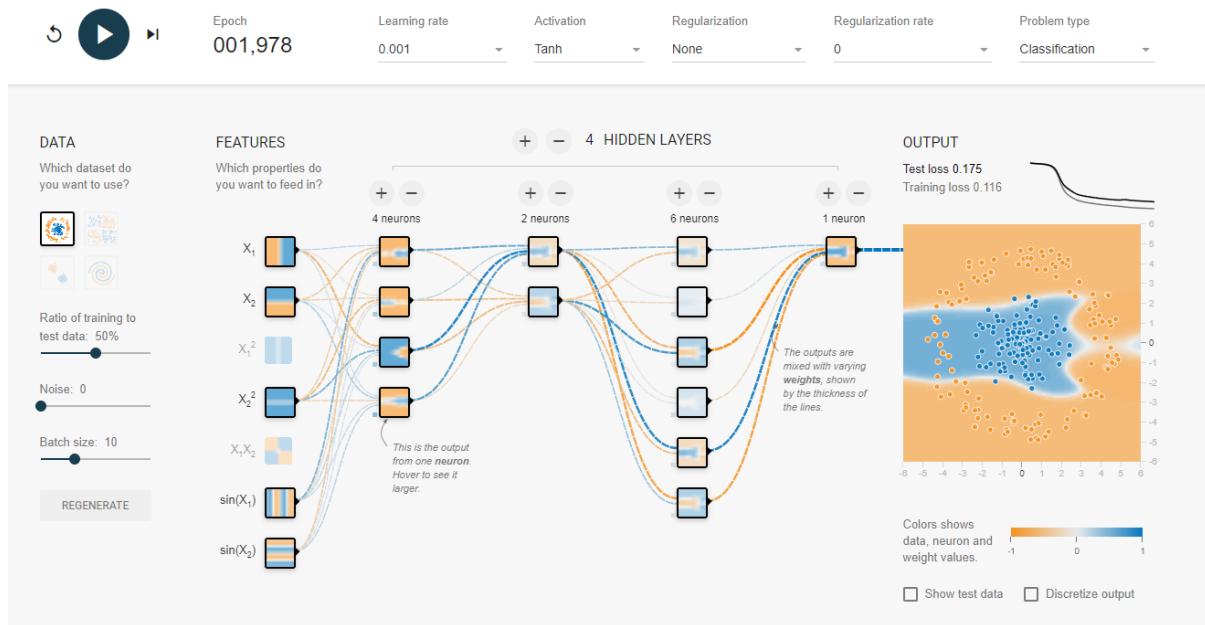
### Learning rate 0.03:



### Learning rate 3:

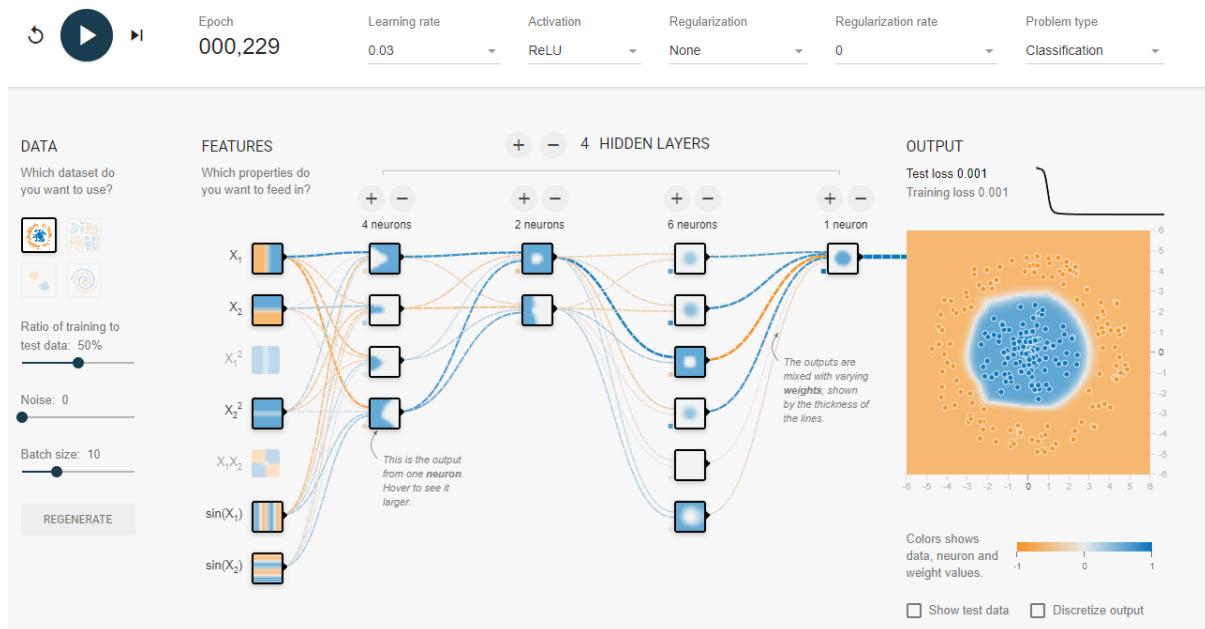


### Learning rate 0,001:

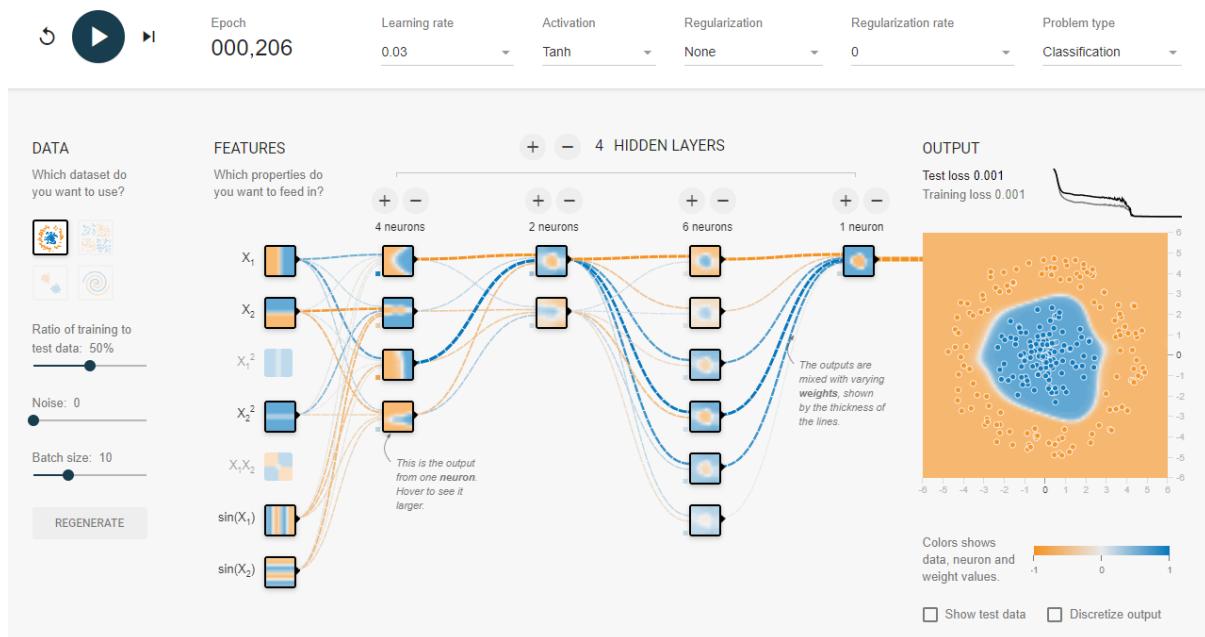


### 2.2 Activation Typ zbioru 1

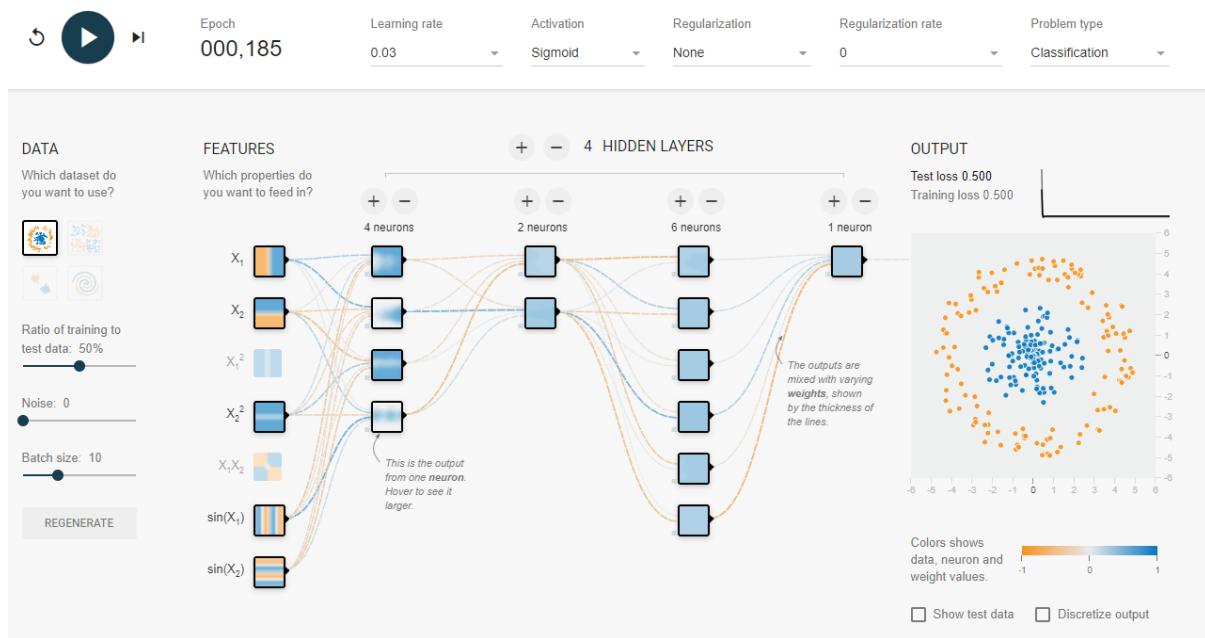
Activation ReLU:



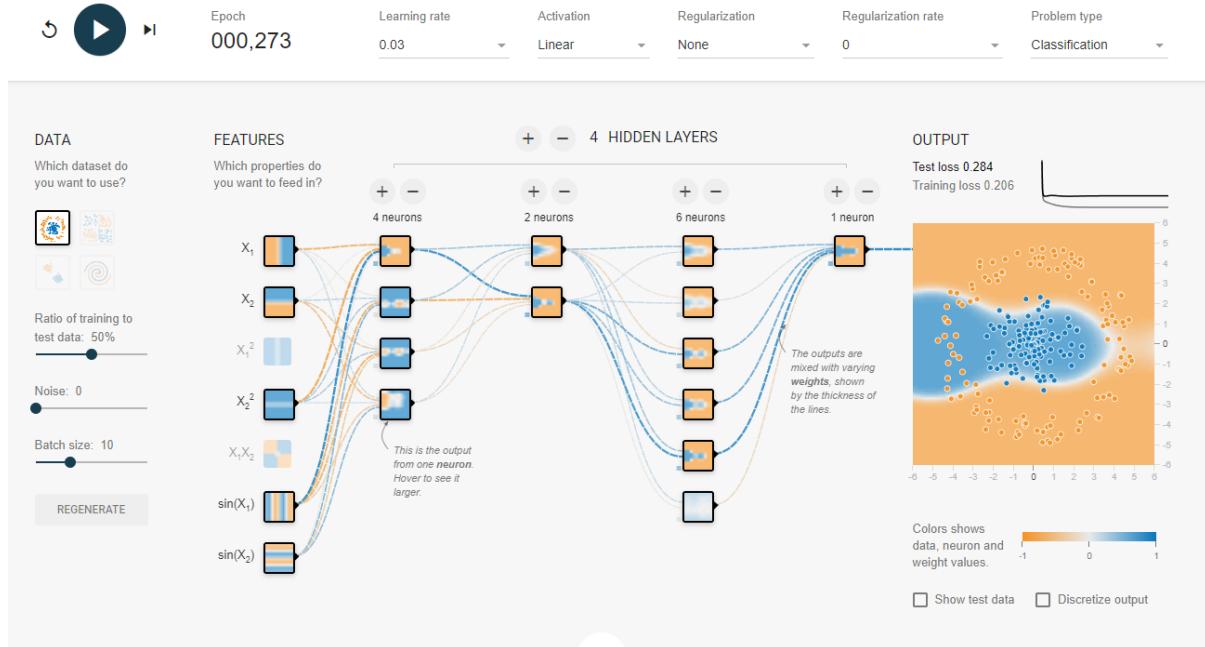
### Activation tanh:



### Activation Sigmoid:

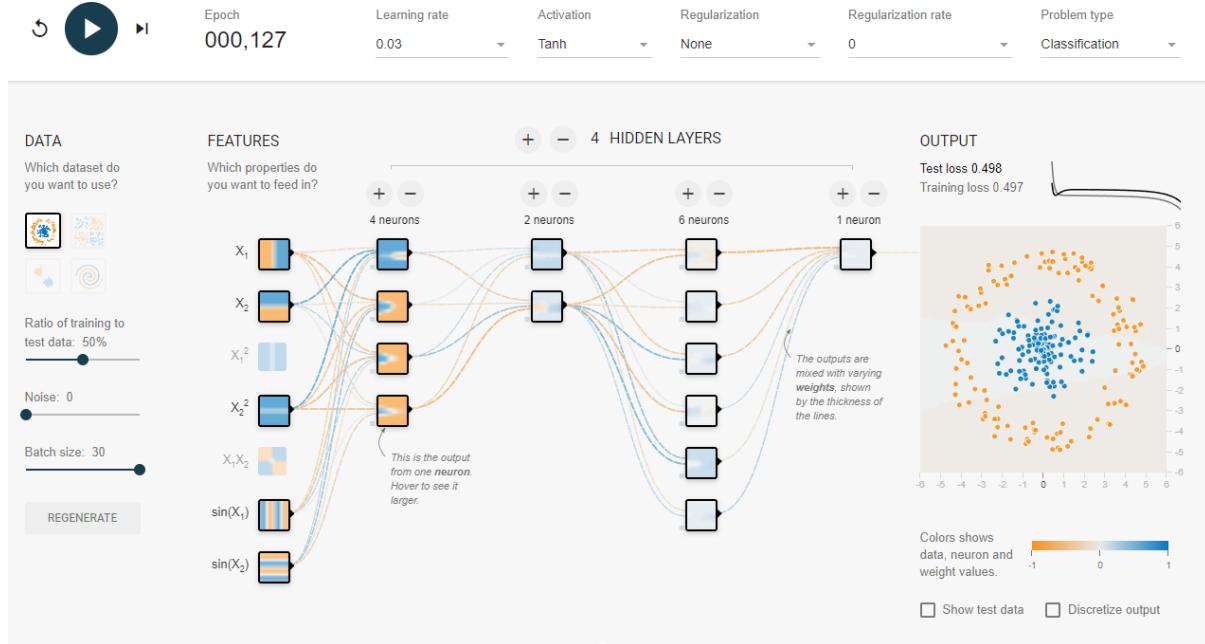


### Activation Linear:

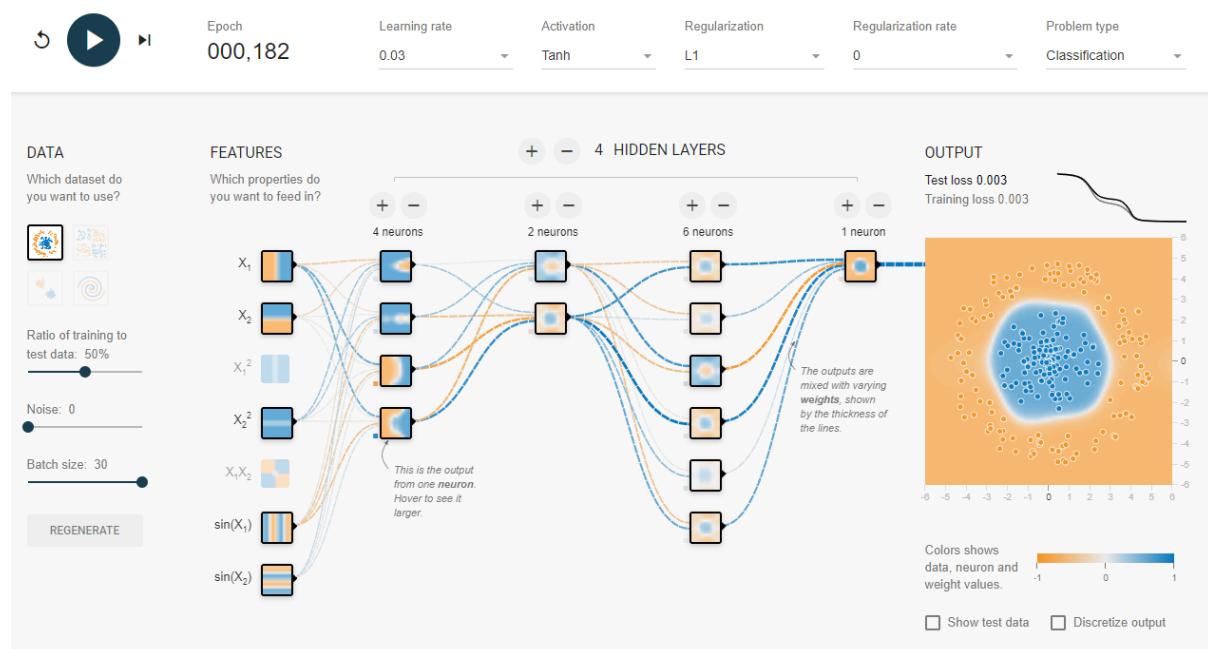


### 2.3 Regularization Typ zbioru 1

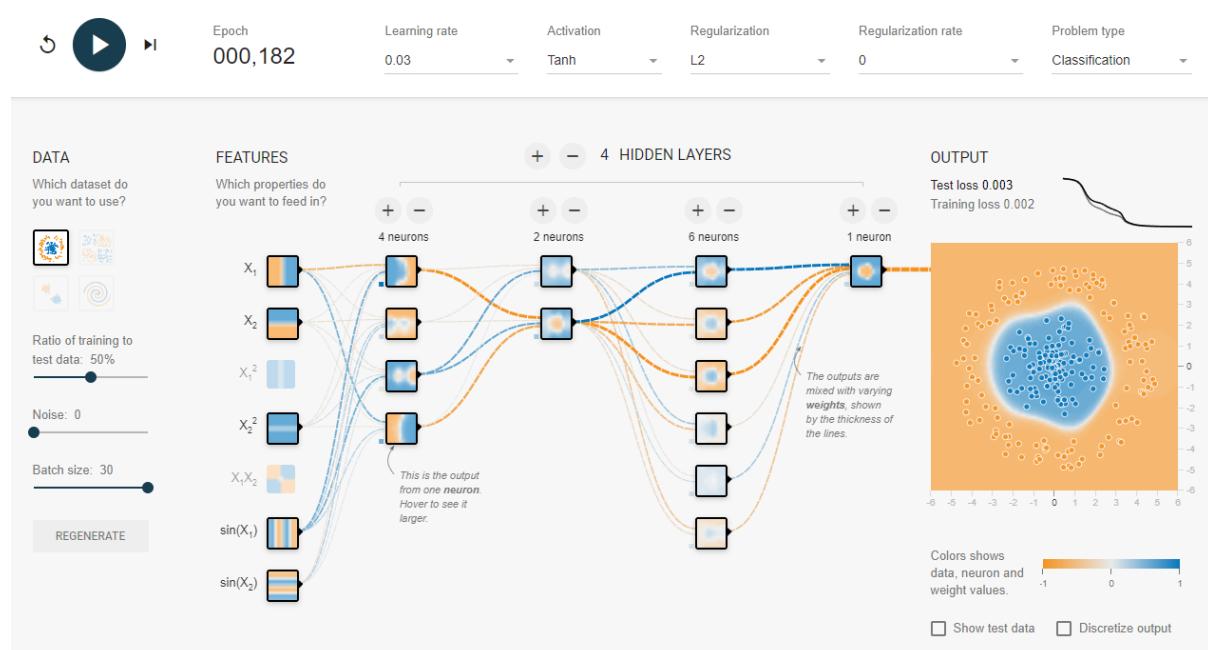
#### Regularization None:



### Regularization L1:

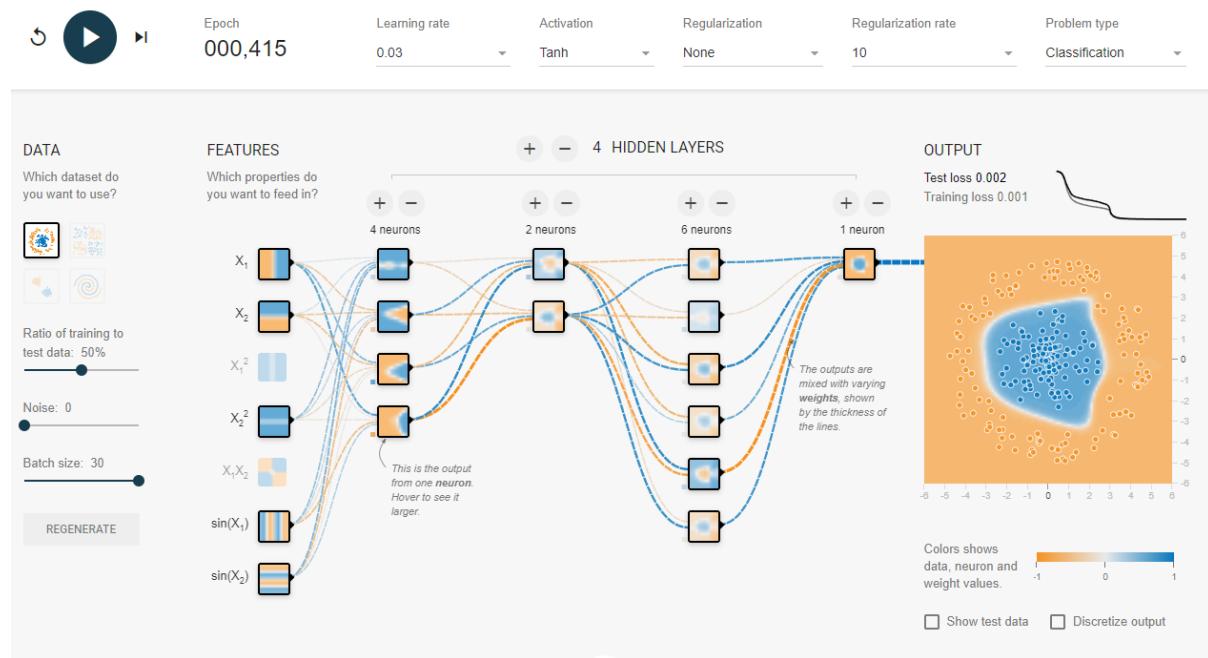


### Regularization L2:

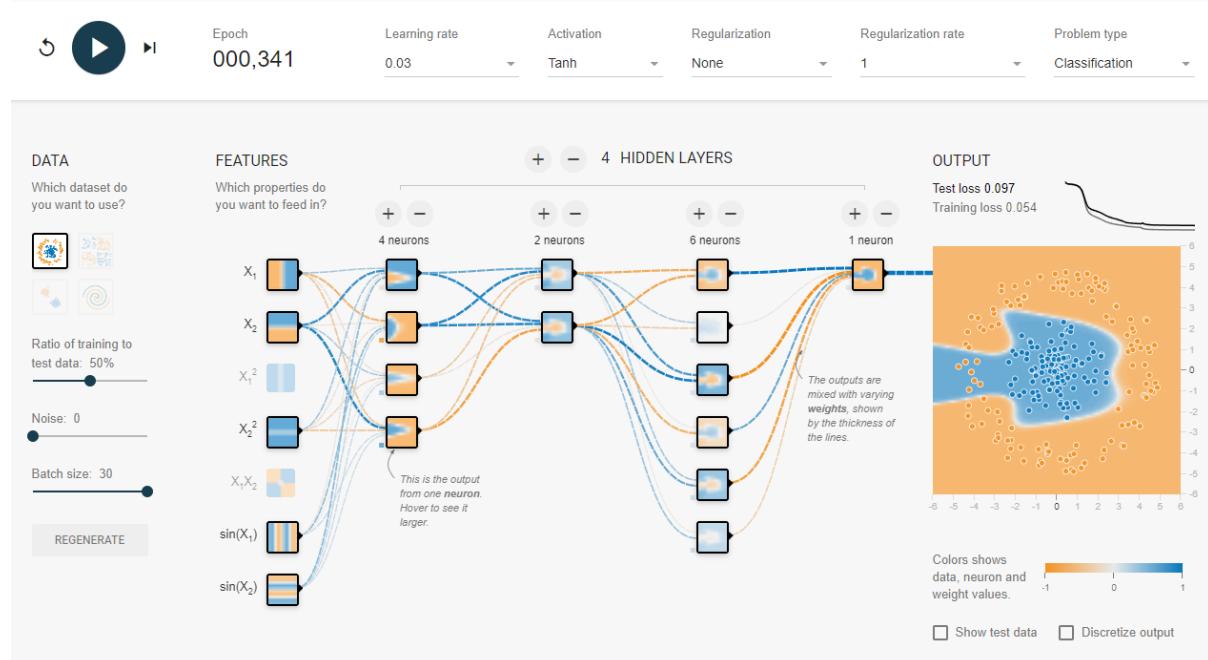


## 2.4 regularization rate Typ zbioru 1

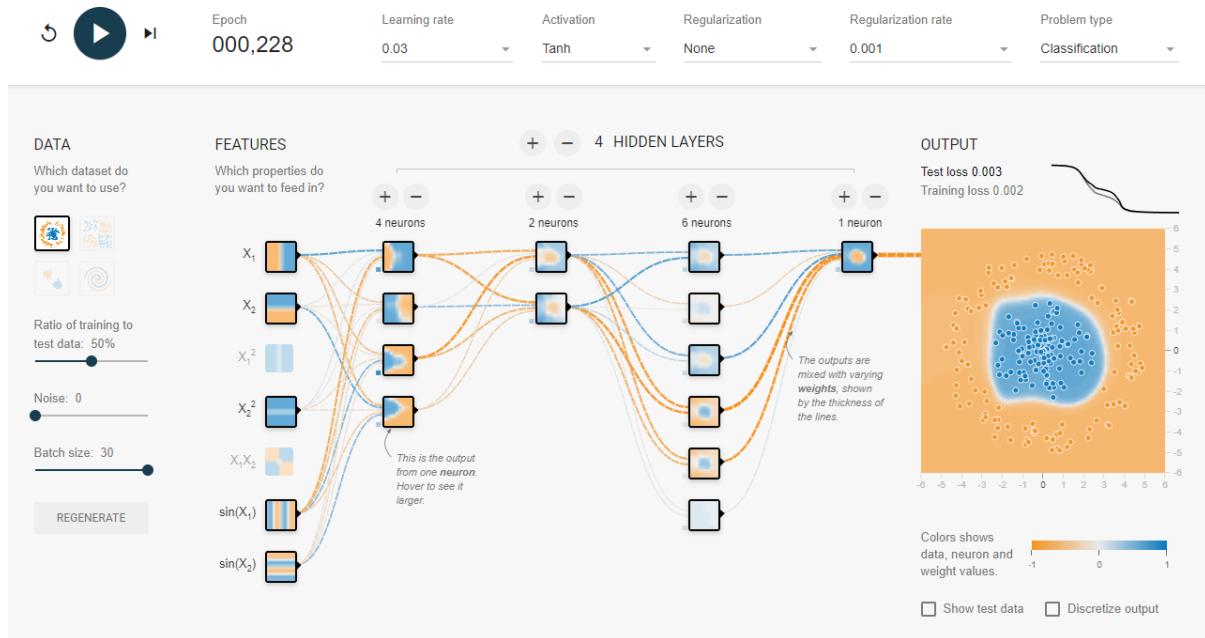
regularization rate 10:



regularization rate 1:

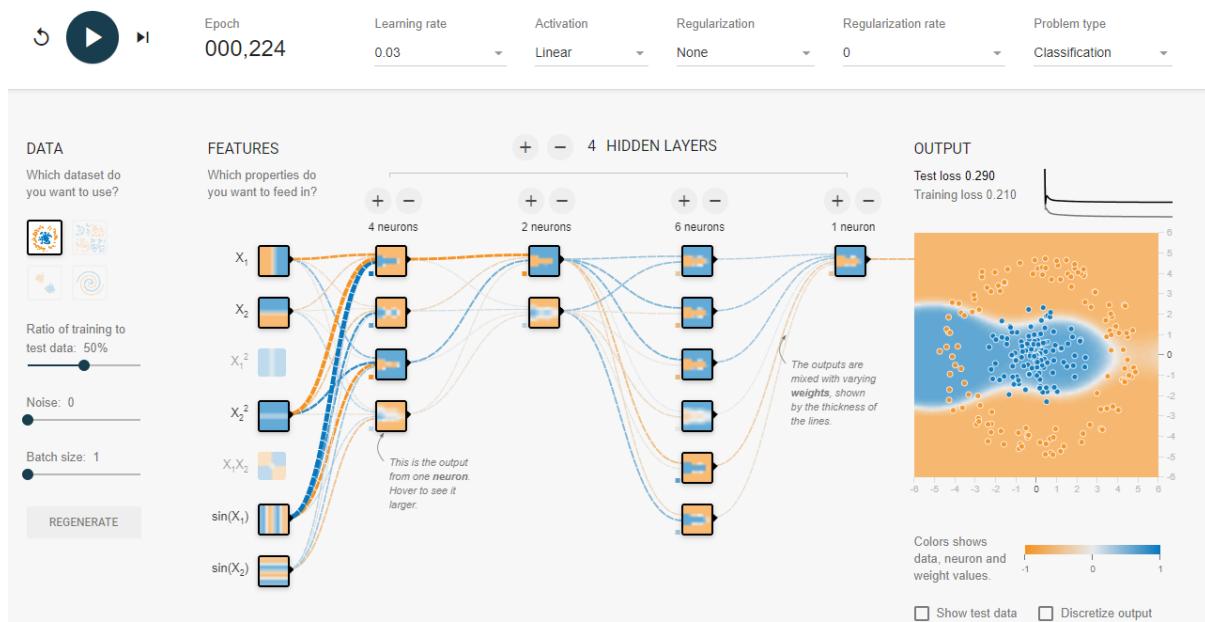


regularization rate 0,001:

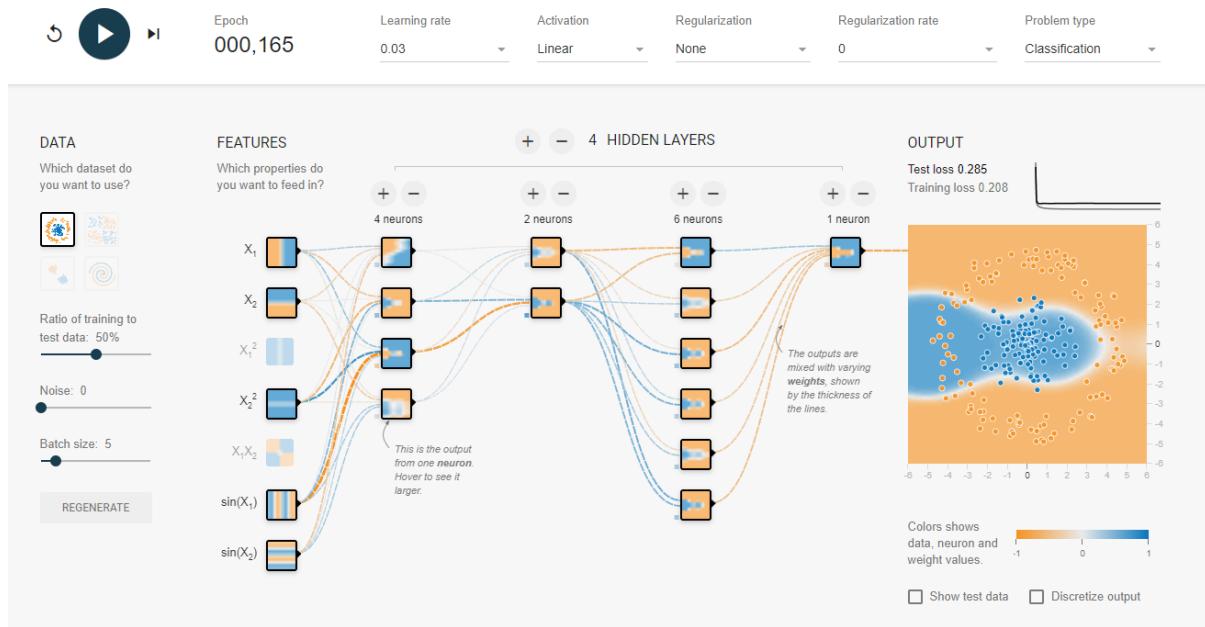


### 3.1 Batch size:

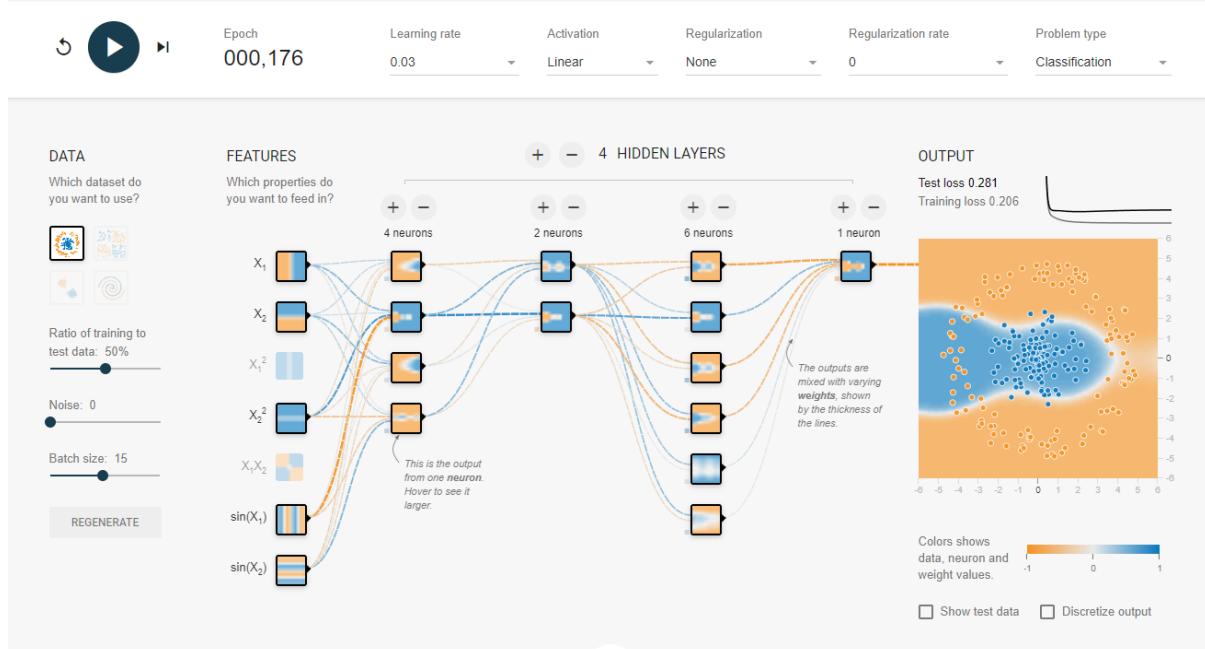
Batch Size 1:



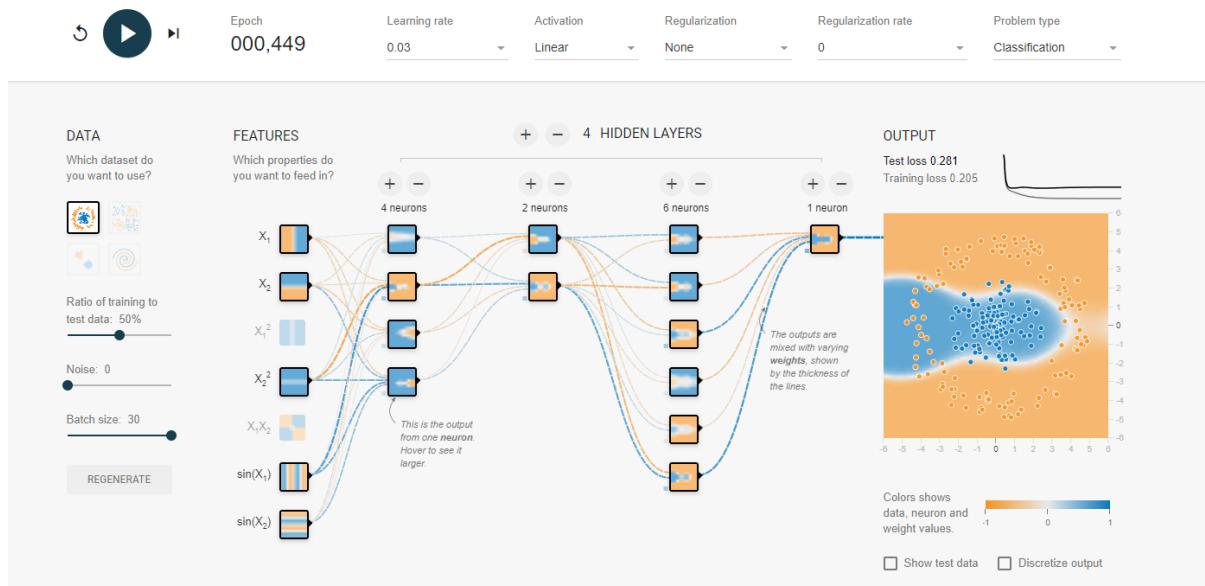
### Batch Size 5:



### Batch Size 15:

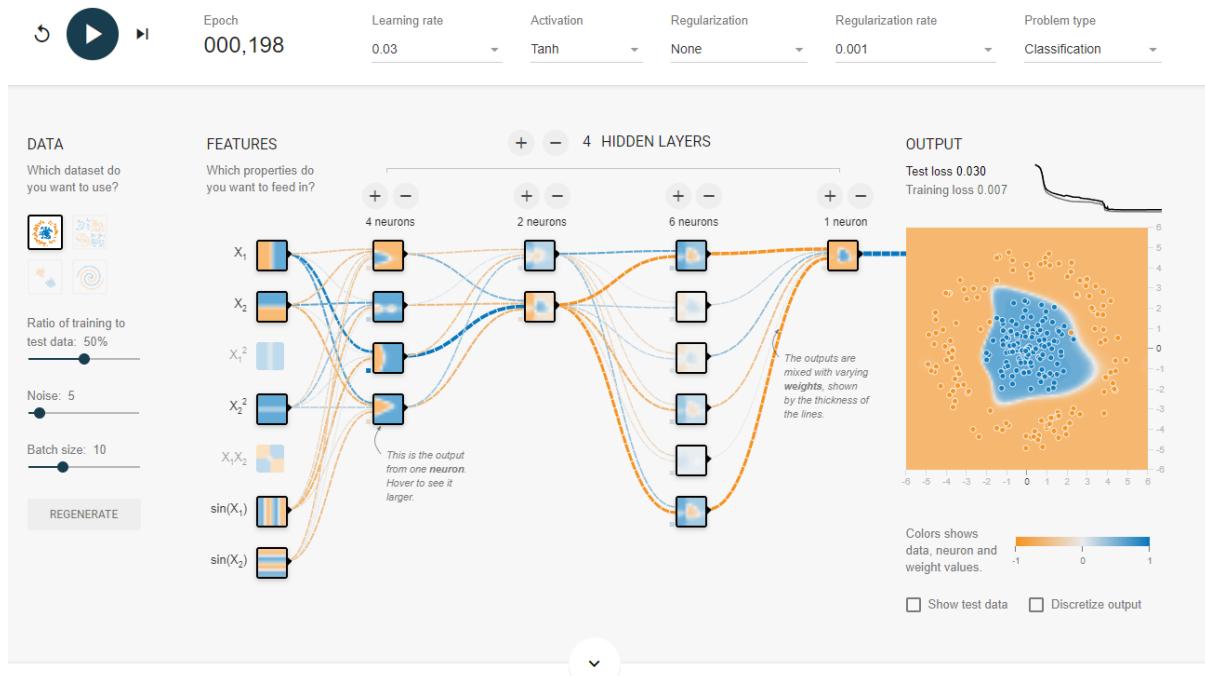


Batch Size 30:

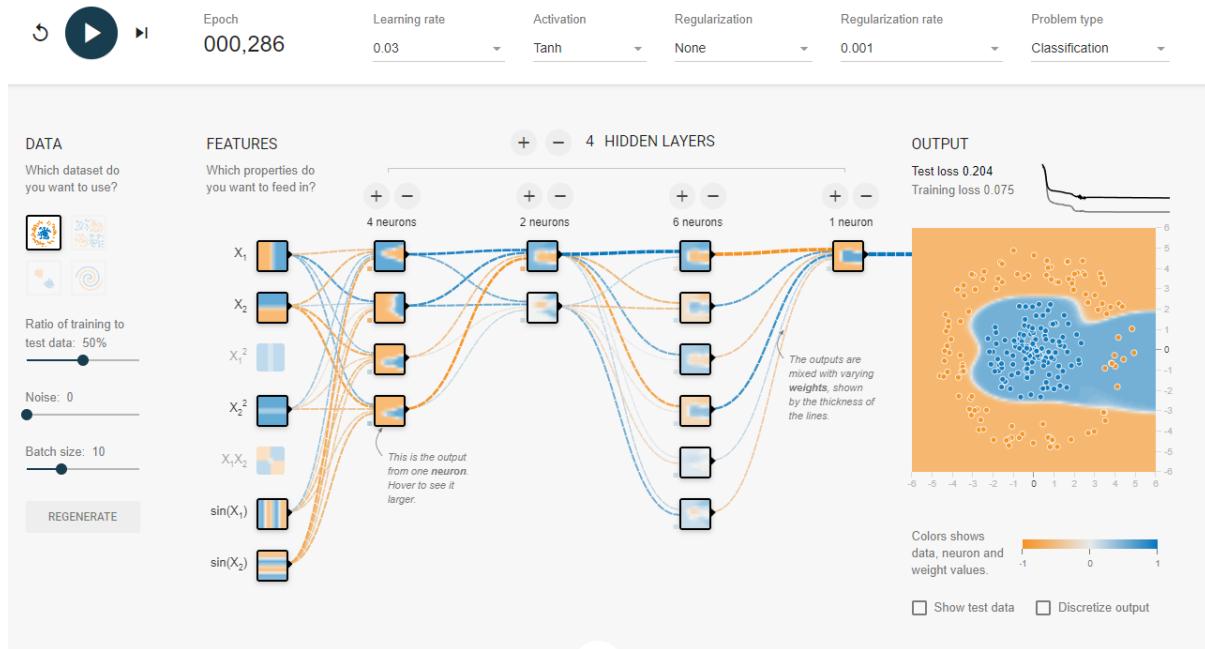


4.1 Szum:

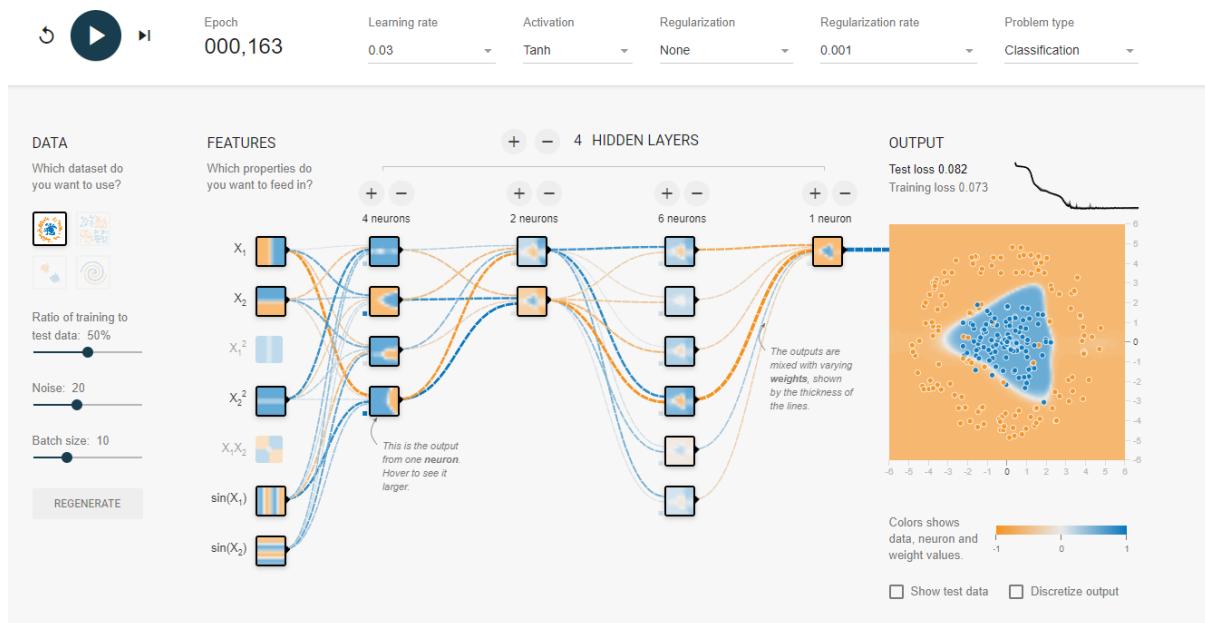
Szum 5:



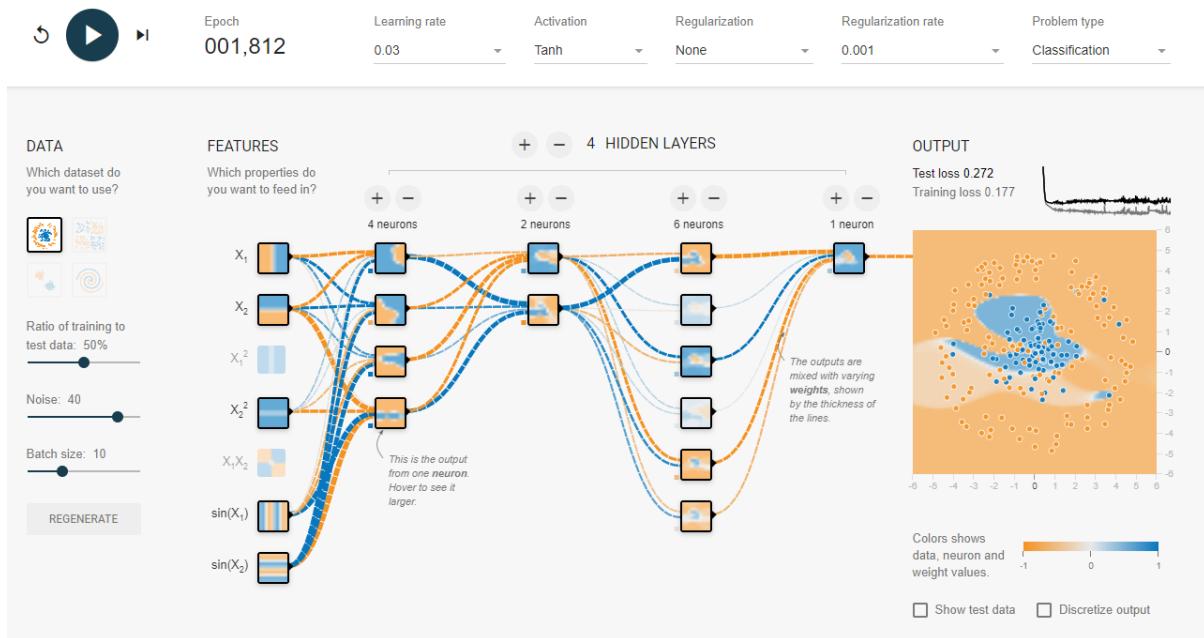
Szum 0:



Szum 20:

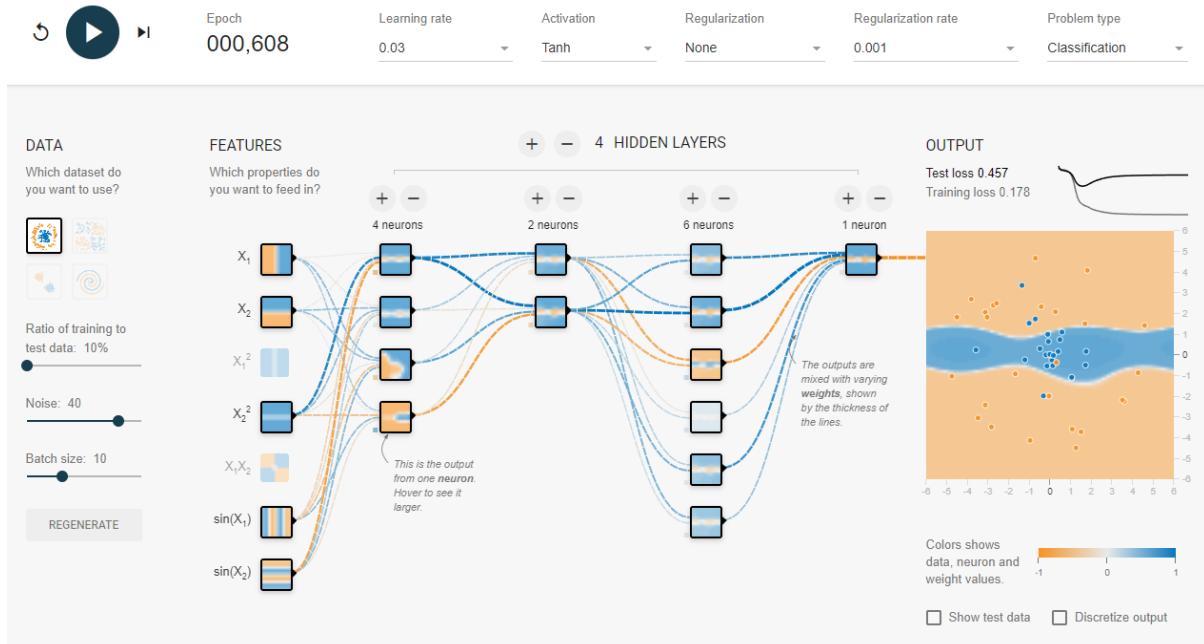


Szum 40:

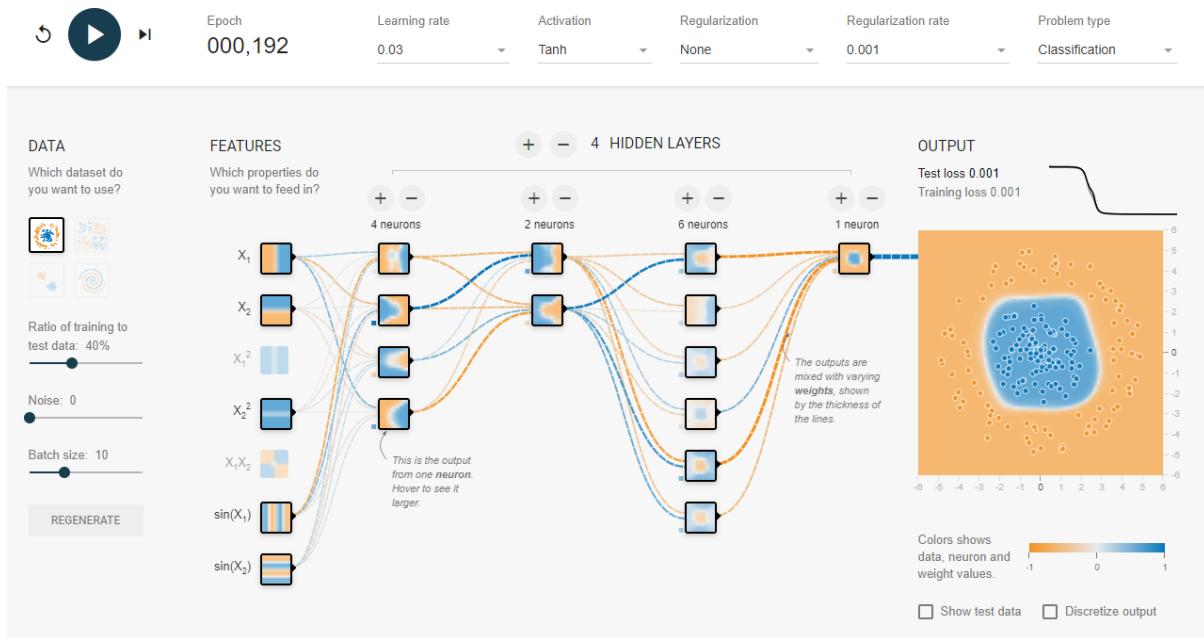


5.1 wpływ wielkości testowego zbioru.

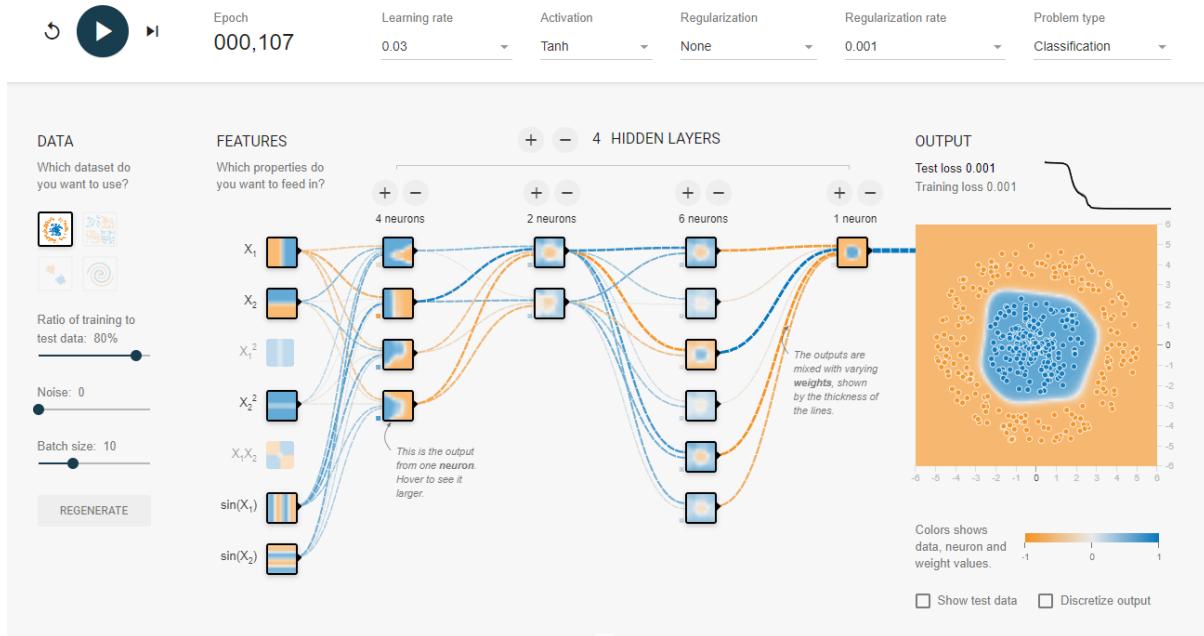
Ratio of training to test data 10%:



Ratio of training to test data 40%:



Ratio of training to test data 80%:



### 6. pojęcia learning rate, regularization oraz regularization rate

Learning Rate (Współczynnik Uczenia):

Współczynnik uczenia, zwany także learning rate, to parametr, który decyduje o tym, jak szybko model uczy się na podstawie bieżących danych treningowych. W kontekście algorytmów optymalizacyjnych, takich jak gradientowy spadek (gradient descent), learning rate określa, jak duże kroki podejmuje algorytm w kierunku minimalizacji funkcji kosztu. Zbyt mały współczynnik uczenia może prowadzić do wolnego postępu w uczeniu i zatrzymania się w lokalnych minimach. Zbyt duży

natomiast może powodować oscylacje i trudności z osiągnięciem minimum. Optymalny współczynnik uczenia zależy od konkretnego problemu i może wymagać eksperymentowania, aby go dostosować.

Regularizacja:

Regularizacja to technika wykorzystywana w uczeniu maszynowym w celu zapobieżenia przeuczeniu (overfittingowi) modelu. Przeuczenie występuje, gdy model zbytnio dostosowuje się do danych treningowych i nie generalizuje dobrze na nowe dane. Regularizacja ma na celu ograniczenie złożoności modelu, co pomaga w ogólnym lepszym uogólnianiu na nowe dane. Istnieje kilka rodzajów regularizacji, ale najczęściej stosowane to:

L1 Regularizacja (Lasso): Dodaje do funkcji kosztu wartości bezwzględne współczynniki wag, co może prowadzić do rzadkich modele (wiele wag jest zerowych).

L2 Regularizacja (Ridge): Dodaje do funkcji kosztu kwadraty wag, co skutkuje zmniejszeniem wartości wszystkich wag, ale niekoniecznie do wartości zerowych.

Elastyczna Net (Elastic Net): To połączenie L1 i L2 regularizacji, łączące ich cechy.

Regularizacja Rate (Współczynnik Regularizacji):

Współczynnik regularizacji, znany także jako regularization rate lub lambda, kontroluje siłę wpływu regularizacji na model. Wartość tego parametru wpływa na to, jak bardzo algorytm optymalizacyjny uwzględnia elementy regularizacyjne w procesie minimalizacji funkcji kosztu. Wyższa wartość tego współczynnika prowadzi do większego ograniczenia wag i zwiększonej roli regularizacji. Wartość ta również może wymagać dostrojenia w zależności od konkretnego problemu i charakterystyk danych.

Podsumowując, learning rate wpływa na kroki algorytmu optymalizacyjnego, regularizacja pomaga w kontrolowaniu przeuczenia poprzez modyfikację wag, a regularization rate określa siłę wpływu regularizacji na proces uczenia. Te trzy pojęcia są istotne przy projektowaniu i trenowaniu efektywnych modeli w uczeniu maszynowym

## Rozdział 3 – Podsumowanie i wnioski

Eksperymentowanie z różnymi parametrami i technikami w uczeniu maszynowym jest niezwykle ważne, ponieważ pozwala lepiej zrozumieć, jak model zachowuje się w zależności od zmian w tych parametrach. Ostatecznym celem jest znalezienie optymalnej konfiguracji modelu, która najlepiej rozwiązuje dany problem. Oto dlaczego to jest tak istotne:

1. **Lepsze zrozumienie modelu:** Eksperymentowanie z różnymi parametrami i technikami pomaga głębiej zrozumieć, jak działa dany model. Pozwala na zrozumienie, które cechy danych są ważne, jakie są ograniczenia modelu i jakie są jego mocne strony.
2. **Unikanie przeuczenia:** Przeuczenie (overfitting) jest częstym problemem w uczeniu maszynowym. Eksperymentowanie z technikami regularizacji, takimi jak L1, L2, czy dropout, pozwala na kontrolowanie przeuczenia i zwiększenie zdolności modelu do generalizacji na nowe dane.
3. **Tuning hiperparametrów:** Wartości hiperparametrów, takie jak learning rate, liczba warstw, liczba neuronów w warstwach, są kluczowe dla wydajności modelu. Eksperymentowanie z różnymi wartościami tych hiperparametrów pozwala znaleźć te, które dają najlepsze wyniki.
4. **Adaptacja do problemu:** Każdy problem w uczeniu maszynowym może mieć swoje własne optymalne ustawienia. Coś, co działa dobrze dla jednego zadania, może nie działać dla innego. Eksperymentowanie pozwala dostosować model do konkretnych wymagań problemu.
5. **Lepsza wydajność:** Ostatecznym celem jest znalezienie konfiguracji modelu, która zapewnia najlepszą wydajność w kontekście określonego zadania. To może prowadzić do bardziej dokładnych przewidywań, lepszej jakości rozwiązań i skrócenia czasu uczenia.
6. **Zrozumienie danych:** Eksperymentowanie może pomóc w lepszym zrozumieniu struktury i charakterystyk danych. To z kolei może pomóc w lepszym przygotowaniu danych i zidentyfikowaniu ważnych cech.

Podsumowując, eksperymentowanie z różnymi konfiguracjami modelu i parametrów jest kluczowe dla sukcesu w uczeniu maszynowym. Pozwala na bardziej elastyczne i efektywne podejście do rozwiązywania problemów, co prowadzi do lepszych wyników i bardziej precyzyjnych modeli.